



CRONOGRAMA DE ANALÍTICA DE DATOS

16 semanas - dos sesiones semanales - 3 créditos

Sem.	Sesión 1	Sesión 2
1	Introducción a la analítica de datos y su importancia. Python: panorama, aplicaciones y primeros pasos.	Anaconda, Jupyter, ambientes virtuales, pip/conda y fundamentos de programación.
2	NumPy, Pandas, Matplotlib y Seaborn: carga, manipulación y visualización inicial.	Metodología CRISP-DM, organización del flujo de trabajo, funciones y manejo básico de excepciones.
3	Análisis exploratorio, estadística descriptiva y visualización de patrones.	Estadística inferencial, formulación de hipótesis e interpretación de resultados.
4	Limpieza de datos, identificación y tratamiento de valores atípicos.	Datos faltantes, imputación, transformación y depuración con Python.
5	Variables cuantitativas y categóricas, normalidad, gráficos Q-Q, transformaciones y dumificación.	Primer parcial.
6	Introducción a machine learning, aprendizaje supervisado, StatsModels y Scikit-Learn; nociones de Perceptrón y Adaline.	Fundamentos de regresión, error, MSE, descenso de gradiente.
7	Regresión lineal y múltiple: coeficientes, R^2 , AIC, MSE y regularización L1/L2.	Regresión logística: probabilidades, coeficientes, pseudo R^2 y umbrales.
8	Matriz de confusión, ROC, AUC y métricas de clasificación.	Funciones discriminantes gaussianas, clasificador bayesiano y Naive Bayes.
9	Discriminante de Fisher, KNN y fundamentos de SVM con kernels.	Árboles de decisión: entropía, Gini, ganancia de información y profundidad.
10	Sobreajuste, subajuste, partición entrenamiento-validación-prueba y validación cruzada.	Pipelines, validación estratificada/LOOCV, curvas de validación y Grid-SearchCV.
11	Sustentación de avances del proyecto del segundo corte.	Segundo parcial.
12	Desbalance de clases, métricas adecuadas y curva precisión-recall.	Submuestreo, sobremuestreo y comparación de estrategias de balanceo.
13	Ensamblados: voto mayoritario, Bagging y Boosting.	Random Forest, Gradient Boosting y ajuste de hiperparámetros.
14	Comparación y selección de clasificadores mediante métricas y validación cruzada.	Reducción dimensional: PCA, MCA, UMAP y LDA.
15	Clustering: K-medias, métodos jerárquicos, dendrogramas y DBSCAN.	Detección de anomalías: mixturas gaussianas, One-Class SVM e Isolation Forest.
16	Cierre integrador e introducción breve a redes neuronales y PyTorch, Keras.	Sustentación de proyectos finales.
17	EXAMEN FINAL	

bibliografía

Raschka, S., & Mirjalili, V. (2019). *Python Machine Learning: Machine Learning and Deep Learning with Python, Scikit-Learn, and TensorFlow 2* (3rd ed.). Packt Publishing. ISBN: 978-1-78995-575-0. McKinney, W. (2022).

Data Mining and Machine Learning: Fundamental Concepts and Algorithms (2nd ed.). Cambridge University Press. DOI: 10.1017/9781108564175.

Python for Data Analysis: Data Wrangling with Pandas, NumPy, and Jupyter (3rd ed.). O'Reilly Media. ISBN: 978-1-09810-403-0. Géron, A. (2019).

Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow: Concepts, Tools, and Techniques to Build Intelligent Systems (2nd ed.). O'Reilly Media. ISBN: 978-1-49203-264-9. Bishop, C. M. (2006).

Pattern Recognition and Machine Learning. Springer. DOI: 10.1007/978-0-387-45528-0; Zaki, M. J., & Meira, W., Jr. (2020).